



**UNIVERSIDAD
DE ANTIOQUIA**

**Ajuste de parámetros sobre Wav2Vec 2.0 para la clasificación de la enfermedad
de Alzheimer mediante señales de voz en condiciones de datos limitados.**

Santiago Alvarez Zuluaga

Trabajo de grado presentado para optar al título de Ingeniero de Telecomunicaciones

Modalidad de Práctica

Trabajo de Grado

Asesor

Cristian David Rios Urrego, Magíster (MSc) en Ingeniería de Telecomunicaciones

Universidad de Antioquia

Facultad de Ingeniería

Ingeniería de Telecomunicaciones

Medellín, Antioquia, Colombia

2026



Cita

Muñoz Zapata y Martínez Naranjo [1]

Referencia

- [1] L. Muñoz Zapata y J. A. Martínez Naranjo, “Título: subtítulo”, Seleccione modalidad de grado, Seleccione pregrado, Universidad de Antioquia, Seleccione ciudad UdeA (A-Z), Seleccione año.

Estilo IEEE (2020)



Grupo de Investigación. Seleccione grupo de investigación UdeA (A-Z).

Seleccione centro de investigación UdeA (A-Z).

Seleccione biblioteca, CRAI o centro de documentación UdeA (A-Z)

Repositorio Institucional: <http://bibliotecadigital.udea.edu.co>

Universidad de Antioquia - www.udea.edu.co

El contenido de esta obra corresponde al derecho de expresión de los autores y no compromete el pensamiento institucional de la Universidad de Antioquia ni desata su responsabilidad frente a terceros. Los autores asumen la responsabilidad por los derechos de autor y conexos.

Dedicatoria

Texto de dedicatoria centrado.

Agradecimientos

Texto de agradecimientos centrado.

TABLA DE CONTENIDO

RESUMEN.....	9
ABSTRACT.....	10
I. INTRODUCCIÓN.....	11
A. <i>Planteamiento del problema</i>	12
B. Estado del arte.....	13
C. Justificación.....	13
II. OBJETIVOS.....	14
A. Objetivo general.....	14
B. Objetivos específicos.....	14
III. MARCO TEÓRICO.....	15
A. Wav2vec 2.0.....	15
1) Pre entrenamiento de WaV2Vec 2.0:.....	15
2) Feature encoder:.....	18
3) Encoder transformer:.....	19
a) <i>Atención multi-cabeza</i>	20
b) <i>Suma residual</i>	20
c) <i>LayerNorm</i>	20
d) <i>Feed-forward</i>	20
e) <i>Segunda suma residual y LayerNorm</i>	21
3) Etapa de clasificación:.....	21
4) Interpretabilidad por capas de representación auto-supervisadas:.....	22
a) Correlación Canonica (CCA).....	23
b) Información Mutua (MI).....	23

c) Localización empírica de los picos de información:.....	24
B. PEFT.....	25
1) Adaptadores (Adapters):.....	27
2). Low-Rank Adaptation (LoRA):.....	28
IV. METODOLOGÍA.....	33
V. ANÁLISIS DE RESULTADOS.....	34
VI. CONCLUSIONES Y RECOMENDACIONES.....	37
REFERENCIAS.....	38
ANEXOS.....	39

LISTA DE TABLAS

TABLA I RESULTADOS DEL TEST.....	19
TABLA II CATEGORÍAS DE INVESTIGACIÓN	20

LISTA DE FIGURAS

Fig. 1. Flujo del Preentrenamiento de Wav2Vec 2.0.....	16
Fig. 2. Arquitectura de Wav2Vec 2.0 para clasificación: (a) feature encoder, (b) encoder Transformer y (c) cabeza de clasificación.....	18
Fig. 3. Estructura de una capa del encoder Transformer de Wav2Vec 2.0.....	20
Fig. 4. Taxonomía de métodos PEFT, con los adapters y LoRA resaltados. Adaptada de Lialin et al. [16].....	26
Fig. 5. Estructura interna de un adapter bottleneck: proyección descendente, no linealidad y proyección ascendente, con conexión residual.....	28
Fig. 6. Factorización de rango de la actualización de pesos ΔW en las matrices de bajo rango B y A.....	30
Fig. 7. Imagen corporativa Institute of Electrical and Electronics Engineers (IEEE).....	36
Fig. 8. Logo Universidad de Antioquia.....	36

SIGLAS, ACRÓNIMOS Y ABREVIATURAS

Cms.	Centímetros
Esp.	Especialista
ERIC	Education Resources Information Center
IEEE	Institute of Electrical and Electronics Engineers
MP	Magistrado Ponente
MSc	Magister Scientiae
Párr.	Párrafo
PhD	Philosophiae Doctor
PBQ-SF	Personality Belief Questionnaire Short Form
PostDoc	PostDoctor
UdeA	Universidad de Antioquia

RESUMEN

El resumen permite identificar la esencia del escrito, mencionando brevemente el objetivo y la metodología, así como los resultados y las conclusiones (mínimo 150, máximo 250 palabras).

***Palabras clave* — Artículo científico, artículo de revisión, investigación, estilos de citación.**

ABSTRACT

El abstract es el mismo resumen pero en idioma inglés. Conserva la misma extensión o aproximada, es decir, mínimo 150 y máximo 250 palabras.

***Keywords* — Scientific article, review article, research, citation styles.**

I. INTRODUCCIÓN

A nivel mundial, la demencia ha sido reconocida por la comunidad internacional como una prioridad creciente de salud pública, dada su magnitud y su impacto en los sistemas de salud, las familias y los cuidadores [1]. Colombia no es ajena a esta tendencia: entre 2015 y 2024, las muertes asociadas a enfermedades mentales y de la conducta —entre ellas el Alzheimer— se multiplicaron casi cinco veces, y solo en 2024 se registraron 4.320 muertes atribuidas específicamente a esta enfermedad, según cifras del DANE [2]. Sin embargo, a pesar de esta carga creciente, estudios recientes señalan que la demencia continúa siendo un problema de salud pública invisibilizado en el país, sin que existan a la fecha políticas públicas específicas que respondan a su magnitud [3]. Esta brecha resulta particularmente paradójica si se considera que Colombia alberga uno de los hallazgos genéticos más relevantes a nivel mundial para la investigación del Alzheimer de inicio temprano: la mutación PSEN1 E280A, conocida como «gen paisa», presente en una familia extendida de la región antioqueña y estudiada durante más de cuatro décadas como modelo único para comprender la progresión clínica de la enfermedad años antes de la aparición de los síntomas [4].

El Alzheimer es una enfermedad neurológica progresiva que, más allá del deterioro de la memoria, compromete funciones cognitivas asociadas al lenguaje; las dificultades comunicativas se cuentan entre los grupos de síntomas que con mayor frecuencia acompañan la enfermedad [5]. El diagnóstico del Alzheimer se ha apoyado tradicionalmente en la evaluación clínica y la neuroimagen estructural, complementadas en las últimas dos décadas por pruebas de biomarcadores en líquido cefalorraquídeo (LCR) y tomografía por emisión de positrones (PET); sin embargo, estas técnicas presentan baja sensibilidad en etapas tempranas y un acceso limitado debido a su costo elevado y su naturaleza invasiva [6]. Teniendo en cuenta este panorama, resulta urgente explorar alternativas de detección que superen las limitaciones de los métodos diagnósticos tradicionales. Muchas evaluaciones neurológicas, aunque clínicamente valiosas, no están diseñadas para ser realizadas de forma masiva y constante atendiendo a la magnitud que el problema exige, retrasando la intervención terapéutica y empeorando el pronóstico de los pacientes [5]. Frente a estas barreras, los biomarcadores han cobrado relevancia como una estrategia complementaria capaz de ofrecer diagnósticos más accesibles y económicos [6]. En

este contexto, el análisis de habla constituye un procedimiento simple, económico y no invasivo, con potencial para la detección del Alzheimer incluso en etapas preclínicas [5]. No obstante, el desarrollo de sistemas automáticos de clasificación basados en habla conlleva una limitación estructural reconocida en la literatura: el tamaño reducido de las muestras disponibles que responde a una dificultad en la recolección de datos de habla en poblaciones con deterioro cognitivo [5].

Los modelos de aprendizaje autosupervisado han revolucionado la manera en que se generan representaciones de habla, permitiendo capturar estructuras acústicas y lingüísticas ricas a partir de grandes volúmenes de audio sin necesidad de transcripciones o etiquetas manuales [7]. Sin embargo, este paradigma no elimina la dependencia de datos: el pre entrenamiento se apoya en corpus masivos no etiquetados, y el ajuste posterior a una tarea específica (el fine-tuning) asume también la disponibilidad de conjuntos de datos etiquetados suficientemente amplios para ajustar el gran número de parámetros que un modelo de este tamaño requiere.

A. Planteamiento del problema

Esta suposición representa un gran problema al trasladar estos métodos al dominio clínico de las enfermedades neurodegenerativas: las bases de datos de habla con etiquetas de Alzheimer disponibles públicamente son, por naturaleza, reducidos. ADReSS reúne apenas 156 hablantes [8], esta cantidad de muestras es órdenes de magnitud menores que los corpus empleados para el pre entrenamiento de Wav2Vec 2.0.

Frente a esta tensión, han surgido estrategias de ajuste eficiente de parámetros, conocidas en inglés como Parameter-Efficient Fine-Tuning (PEFT) diseñadas justamente para adaptar modelos de gran tamaño con pocos datos; sin embargo, estas estrategias no se han aplicado a la clasificación de Alzheimer frente a controles sanos a partir de Wav2Vec 2.0. Es en esta ausencia donde se sitúa el aporte metodológico central de la presente propuesta. ¿Cómo construir un clasificador robusto, capaz de distinguir entre hablantes con Alzheimer y controles sanos, en condiciones de datos limitados?

*B. Estado del arte**C. Justificación*

Frente a esta escasez de datos, en este trabajo se propone aplicar y comparar diferentes estrategias de adaptación sobre Wav2Vec 2.0 para la tarea de clasificación binaria entre hablantes con Alzheimer y controles sanos: adaptadores tipo bottleneck, que insertan módulos secuenciales de baja dimensionalidad entre las capas del modelo [9]; adaptaciones de bajo rango, conocidas por sus siglas en inglés LoRA (Low Rank Adaptation), que introduce una corrección de bajo rango sobre las matrices de pesos existentes sin modificarlas directamente [10]; y el descongelamiento parcial de las últimas n capas del modelo, como forma más directa de ajuste. Estas tres estrategias serán evaluadas frente a un mismo punto de referencia fijo: Wav2Vec 2.0 sin ningún ajuste de sus pesos. A partir de este diseño experimental, la presente propuesta plantea como hipótesis central que el ajuste del modelo, mediante cualquiera de las estrategias mencionadas, permite obtener un desempeño de clasificación superior al del modelo congelado, incluso en condiciones de datos etiquetados limitados.

II. OBJETIVOS

A. Objetivo general

Desarrollar una estrategia de ajuste de parámetros sobre modelos fundacionales auto-supervisados, como Wav2Vec 2.0, para la clasificación de pacientes con enfermedad de Alzheimer frente a controles sanos mediante señales de voz en condiciones de datos limitados.

B. Objetivos específicos

- Establecer una línea base de clasificación de pacientes con enfermedad de Alzheimer y sujetos de control mediante el uso de representaciones extraídas por Wav2Vec 2.0 sin ajuste de parámetros.
- Identificar estrategias de ajuste de parámetros aplicables a la arquitectura de Wav2Vec 2.0 para tareas de clasificación binaria en escenarios con datos limitados.
- Implementar diferentes estrategias de ajuste de parámetros sobre el modelo fundacional Wav2Vec 2.0, con el fin de adaptarlo a la tarea de clasificación binaria entre pacientes con la enfermedad de Alzheimer y sujetos de control.
- Evaluar y comparar el desempeño de clasificación, el tiempo de entrenamiento, el tiempo de inferencia y el número de parámetros entrenables entre el enfoque del modelo base y las estrategias de ajuste implementadas.

III. MARCO TEÓRICO

A. Wav2vec 2.0

Wav2Vec 2.0 [7] es un modelo de aprendizaje autosupervisado que aprende representaciones de habla directamente del audio crudo, sin necesidad de transcripciones. Antes de describir la arquitectura al detalle, es necesario distinguir dos momentos en su ciclo de vida que involucran componentes distintos. El preentrenamiento es el proceso mediante el cual el modelo aprende sus representaciones de forma autosupervisada; en esta etapa existen un cuantizador, dos codebooks y dos funciones de pérdida (contrastiva y de diversidad) que son exclusivos de esta fase. De manera general al utilizar este tipo de modelos se parte del modelo ya preentrenado y nunca se reconstruye ni ejecuta el cuantizador, los codebooks o las pérdidas de preentrenamiento.

1) Pre entrenamiento de WaV2Vec 2.0:

El *feature encoder* transforma la señal cruda en una secuencia de vectores latentes continuos $z_1, \dots, z_T$, uno por cada fotograma de 25 ms. Esta secuencia z alimenta en paralelo dos ramas independientes durante el *forward*. En la primera, antes de ingresar al *Transformer*, se enmascaran tramos contiguos: se muestrea una proporción $p \approx 65$ de los pasos como índices de inicio, y desde cada uno se cubren $M=10$ pasos consecutivos con un único vector entrenable compartido (el *mask embedding*). Por el solapamiento entre tramos, el resultado es que cerca del 49% de la secuencia queda enmascarada. Esta estrategia de bloques (en vez de fotogramas aislados) sigue una lógica similar a *SpecAugment* [11]: los fotogramas vecinos están altamente correlacionados, de modo que enmascarar uno solo permitiría reconstruirlo por simple interpolación, mientras que cubrir un tramo completo obliga al modelo a recurrir a contexto de largo alcance.




Fig. 1. Flujo del Preentrenamiento de Wav2Vec 2.0

La secuencia z parcialmente enmascarada entra al Transformer, que produce una representación contextualizada c_t para cada posición mediante auto-atención: cada posición, actuando como *query* Q , calcula su similitud contra las *keys* K de todas las posiciones mediante el producto punto $Q \cdot K$; luego se normaliza esos puntajes con una función *softmax*, y construye su salida como una suma ponderada de los *values* V de las posiciones a las que atiende. En las posiciones enmascaradas, dado que el *mask embedding* no contiene información real del fotograma original, c_t se reconstruye enteramente a partir del contexto (las posiciones vecinas no enmascaradas) y no de su propia entrada.

En la segunda rama, la misma secuencia z alimenta un cuantizador que discretiza cada vector en una representación de un conjunto finito de unidades aprendidas, mediante dos codebooks ($G=2$ grupos), cada uno es una matriz de $V=320$ filas por d/G columnas, (siendo d la dimensión del vector que resulta de concatenar las G filas seleccionadas) inicializadas aleatoriamente y ajustadas por la propagación hacia atrás como cualquier otro peso del modelo. Para cuantizar un fotograma, una capa lineal proyecta z a un conjunto de logits $l \in \mathbb{R}^{G \times V}$; un mecanismo de *Gumbel-softmax* selecciona un índice por grupo; se extraen las filas correspondientes de cada *codebook* y se concatenan en un vector de dimensión d ; y una transformación lineal final produce el vector cuantizado q . Esta estructura de *product quantization* permite representar hasta $V^2=102.400$ combinaciones distintas almacenando únicamente $G \times V = 640$ vectores, una ganancia de eficiencia frente a un *codebook* único que requeriría almacenar esas 102.400 combinaciones de forma independiente.

La selección discreta de filas (una operación *argmax*, no diferenciable) se entrena mediante *straight-through estimator* combinado con ruido de *Gumbel*. Sobre cada logit $l_{g,v}$ se suma un ruido n_v muestreado de una distribución de *Gumbel*; la propiedad conocida como *Gumbel-max trick* garantiza que $\text{argmax}(l+n)$ equivale a muestrear una fila con probabilidad $\text{softmax}(l)$, introduciendo la exploración necesaria durante el entrenamiento. Para permitir la propagación del gradiente se define:

$$p_{g,v} = \frac{\exp(l_{g,v} + n_v) / \tau}{\sum_{k=1}^V \exp(l_{g,k} + n_k / \tau)} \quad (1)$$

En el *forward* se toma el *argmax* de esta distribución (selección dura, tipo *one-hot*, que ignora τ); en el *backward* se emplea el gradiente del *softmax* completo, suave y diferenciable, con una temperatura τ positiva que decrece gradualmente durante el entrenamiento (de 2 a 0.5, sin llegar nunca a 0).

El modelo se entrena mediante dos pérdidas combinadas. La pérdida contrastiva $\mathcal{L}_m$ evalúa, en cada posición enmascarada, si c_t permite distinguir su versión cuantizada verdadera q_t

frente a un conjunto de distractores Q_t (otros q muestreados de otras posiciones enmascaradas del mismo audio), mediante similitud coseno escalada por una temperatura k :

$$\mathcal{L}_m = -\log \frac{\exp(\text{sim}(\mathbf{c}_t, \mathbf{q}_t)/\kappa)}{\sum_{\tilde{\mathbf{q}} \sim Q_t} \exp(\text{sim}(\mathbf{c}_t, \tilde{\mathbf{q}})/\kappa)} \quad (2)$$

Una pérdida de diversidad $\mathcal{L}_d$ evita que el cuantizador colapse en el uso repetido de solo unas pocas filas de cada *codebook*, maximizando la entropía del uso promedio a lo largo del *batch*:

$$\mathcal{L}_d = \frac{1}{GV} \sum_{g=1}^G -H(\bar{p}_g) = \frac{1}{GV} \sum_{g=1}^G \sum_{v=1}^V \bar{p}_{g,v} \log \bar{p}_{g,v} \quad (3)$$

Donde $\bar{p}_g$ es la probabilidad de selección de cada fila, promediada sobre los fotogramas del *batch* (con un *softmax* plano, sin ruido ni temperatura). El objetivo total combina ambas pérdidas $\mathcal{L} = \mathcal{L}_m + \alpha \mathcal{L}_d$, donde α regula el balance entre utilidad y diversidad de las unidades seleccionadas.

Terminado el preentrenamiento, el cuantizador, los dos codebooks y ambas pérdidas se descartan. Lo único que se conserva y se distribuye en el modelo público es el *feature encoder* y el *encoder Transformer*, más una etapa de clasificación añadida que dependiera del fenómeno en el que estemos interesados analizar.




Fig 2: Arquitectura de Wav2Vec 2.0 para clasificación: (a) feature encoder, (b) encoder Transformer y (c) Etapa de clasificación.

2) *Feature encoder:*

El feature encoder es la primera fase de la arquitectura de Wav2Vec 2.0 y opera directamente sobre el audio crudo, sin ningún paso intermedio de extracción de características tipo espectrograma. Es la misma etapa que produce la secuencia de vectores latentes z descrita en la sección anterior: siete bloques convolucionales 1D, cada uno con 512 canales, con anchos de kernel (10, 3, 3, 3, 3, 2, 2) y strides (5, 2, 2, 2, 2, 2, 2) [12].

El producto de estos siete strides ($5 \times 2 \times 2 \times 2 \times 2 \times 2 \times 2 = 320$) determina el factor de *downsampling* temporal total de la capa: por cada 320 muestras de audio crudo a la entrada, el feature encoder produce un único vector de z a la salida. Para audio muestreado a 16 kHz, esto se traduce en una tasa de salida aproximada de 49 Hz, es decir, un vector cada ~ 20 ms, de modo que cada posición de z resume una ventana corta y solapada de la señal cruda, sin ningún tipo de contexto, el cual se incorpora más adelante, en el encoder Transformer.

3) *Encoder transformer:*

La secuencia z , tras el feature encoder, se proyecta de 512 a 768 dimensiones y se le suma una codificación posicional relativa, implementada como una capa convolucional (kernel de tamaño 128, 16 grupos) en lugar de los embeddings posicionales sinusoidales fijos habituales en el Transformer original. Esto es necesario porque la atención, a diferencia de una convolución o una recurrencia, no distingue por sí sola el orden de los elementos de la secuencia: sin esta señal, el modelo trataría a z como un conjunto no ordenado de vectores.

Cada una de las 12 capas del encoder repite el mismo bloque (Fig. 3), compuesto por los siguientes elementos:




Fig. 2. Estructura de una capa del encoder Transformer de Wav2Vec 2.0.

a) Atención multi-cabeza.

Es el mecanismo que introduce contexto: cada posición, actuando como *query*, calcula su similitud contra las *keys* de todas las demás posiciones de la secuencia mediante el producto punto escalado; esos puntajes se normalizan con una función *Softmax* y la salida de esa posición se reconstruye como una suma ponderada de los *values* de todas las posiciones, dando más peso a aquellas con las que tiene mayor similitud. Que sea "multi-cabeza" (12 cabezas de $d=64$ cada una, sumando 768) significa que esta operación se repite en paralelo 12 veces, cada una sobre una proyección distinta del mismo vector; esto permite que cada cabeza se especialice en capturar un tipo distinto de relación entre diferentes posiciones.

b) Suma residual.

La salida de las cabezas de atención no reemplaza la entrada original del bloque, con el fin de evitar que la información original del fotograma se pierda al pasar por la atención y facilitar la propagación del gradiente durante el entrenamiento cuando se apilan muchas capas el contenido original que entra al *encoder* se suma con la salida contextualizada. Sin esta suma, el gradiente tendería a degradarse a medida que la señal atraviesa las 12 capas.

c) LayerNorm.

Normaliza el vector resultante (media 0, varianza 1 a lo largo de la dimensión de características) antes de continuar. Esto estabiliza la magnitud de las activaciones capa tras capa, evitando que crezcan o se degraden de forma descontrolada conforme la señal avanza por las 12 capas.

d) Feed-forward.

Es una red de dos capas lineales aplicada de forma independiente a cada posición de la secuencia: primero expande la dimensión de 768 a 3072, aplica una no linealidad GELU, y luego proyecta de vuelta a 768. Mientras que la atención decide de qué otras posiciones tomar información, la feed-forward transforma el contenido de cada posición de forma no lineal, añadiendo capacidad de representación que la atención por sí sola no provee.

e) Segunda suma residual y LayerNorm.

Se repite el mismo patrón: la salida de la feed-forward se suma a su entrada (por la misma razón que la primera suma residual) y el resultado se normaliza, cerrando el bloque.

Apilando 12 de estos bloques se obtiene, para cada fotograma de la secuencia, una representación contextualizada C (49×768) que a diferencia de z , que solo resume una ventana corta de audio crudo, ya incorpora información de toda la secuencia gracias a las 12 rondas sucesivas de atención.

3) Etapa de clasificación:

En el paper original, Wav2Vec2.0 se evalúa fundamentalmente como modelo base para reconocimiento automático de habla (ASR): la tarea de transcribir una señal de audio a su secuencia de texto correspondiente [7]. Para esto, la cabecera que se coloca sobre el Transformer preentrenado es una única capa lineal, inicializada aleatoriamente, que proyecta cada vector de la secuencia contextualizada C a un conjunto de logits sobre el vocabulario de la tarea; en el *corpus* LibriSpeech ese vocabulario son 29 tokens de caracteres más un token de separación de palabra $[x]$, y en TIMIT (reconocimiento de fonemas) son 39 clases fonéticas $[x]$. Esta etapa conserva la longitud temporal de C (produce una predicción por cada fotograma, no una única predicción por audio) porque el problema que resuelve es de secuencia a secuencia sin un alineamiento conocido entre fotogramas de entrada y símbolos de salida; por eso se entrena con la pérdida CTC (Connectionist Temporal Classification), que evita necesitar ese alineamiento sumando sobre todas las segmentaciones posibles compatibles con la secuencia a encontrar.

Adaptar Wav2Vec 2.0 a una tarea de clasificación implica reutilizar el modelo preentrenado, descartando el cuantizador (empleado solo en preentrenamiento) y reemplazando la etpa de CTC por una nueva dado que C tiene longitud variable (depende de la duración del audio) y una tarea de clasificación requiere una única predicción por audio. Debido a esto es necesario colapsar C a un vector de dimensión fija antes de clasificar. Esto se resuelve con una operación de pooling temporal (las variantes más comunes en la literatura son mean pooling, max pooling o pooling ponderado por atención) seguida de una o más capas que proyectan ese vector fijo a K clases. Al desaparecer el problema de alineamiento (ya no hay una secuencia de salida que alinear con la de entrada), la pérdida cambia de la formulación contrastiva de preentrenamiento a una entropía cruzada estándar:

$$\mathcal{L}_{CE} = - \sum_c y_c \log(\hat{y}_c) \quad (4)$$

Donde y_c es la etiqueta verdadera y $\hat{y}_c$ la probabilidad predicha para la clase c .

4) Interpretabilidad por capas de representación auto-supervisadas:

Una red neuronal profunda como wav2vec 2.0 está compuesta por una secuencia de capas apiladas, cada una de las cuales transforma la representación recibida de la capa anterior en una nueva representación intermedia. Si bien el desempeño de estos modelos está bien documentado en diferentes tareas, esto no implica que se conozca qué tipo de información codifica cada capa individualmente, ni como esa información varía a lo largo de la profundidad de la red.

Existen dos aproximaciones generales para responder esta pregunta. La primera consiste en entrenar un clasificador auxiliar ("sonda" o *probe*) sobre la representación de cada capa, y evaluar su desempeño en una tarea específica (p. ej., clasificación de fonemas)[13]. El problema de este enfoque es que introduce una incertidumbre adicional: si el clasificador obtiene un desempeño bajo, no es posible determinar si esto se debe a que la capa efectivamente no codifica la información buscada, o a decisiones de diseño del propio clasificador (arquitectura, hiperparámetros, cantidad de datos de entrenamiento). Pasad et al (2021) [13] optan en su lugar por un segundo tipo de análisis: medidas estadísticas directas que comparan la representación de

una capa contra una variable externa de interés sin necesidad de entrenar ningún modelo adicional.

a) Correlación Canónica (CCA)

El Análisis de Correlación Canónica es una técnica estadística que cuantifica la relación entre dos representaciones. Dado dos vectores $\mathbf{x} \in \mathbb{R}^{d1}$ (por ejemplo, la salida de una capa del transformer) e $\mathbf{y} \in \mathbb{R}^{d2}$ (por ejemplo, una etiqueta lingüística externa, como la identidad fonética), CCA busca un par de direcciones de proyección $\mathbf{v}$ y $\mathbf{w}$ que maximizan la correlación entre las proyecciones lineales resultantes

$$v_1, w_1 = \operatorname{argmax}_{v,w} \operatorname{corr}(\mathbf{v}^T \mathbf{x}, \mathbf{w}^T \mathbf{y}) (\mathbf{x})$$

El procedimiento se repite iterativamente para encontrar hasta $K = \min(d1, d2)$ pares de direcciones adicionales, cada una sujeta a la restricción de no ser redundante con las anteriores, obteniendo así un conjunto de correlaciones $\rho_1, \rho_2, \dots, \rho_k$.

Pasad et al. (2021) emplean específicamente projection-weighted CCA (PWCCA; Morcos et al., 2018), una variante que pondera cada correlación ρ_i de forma proporcional a la relevancia real de esa dirección dentro del espacio original, en lugar de promediarlas con igual peso.

$$PWCCA(X, Y) = \frac{\sum_i \alpha_i \cdot \rho_i}{\sum_i \alpha_i} (\mathbf{x})$$

Esta ponderación es necesaria porque no todas las direcciones encontradas son igual de confiables: al comparar espacios de alta dimensionalidad con relativamente pocas muestras de datos, algunas de las correlaciones encontradas por CCA reflejan patrones reales, mientras que otras son producto del azar estadístico, por lo tanto, promediarlas con el mismo peso que las direcciones realmente informativas sesgaría la medida final.

b) Información Mutua (MI)

Como complemento a CCA, Pasad et al. (2021) [13] emplean información mutua para capturar dependencias estadísticas de cualquier tipo (no únicamente lineales) entre la representación de una capa y una etiqueta discreta externa (identidad fonética o de palabra).

Dadas dos variables discretas X e Y , la información mutua se define como:

$$I(X; Y) = \sum_x \sum_y p(x, y) \log \left(\frac{p(x, y)}{p(x)p(y)} \right) \quad (\mathbf{x})$$

Esta cantidad es nula si y solo si X e Y son estadísticamente independientes, y aumenta en la medida en que conocer una variable reduce la incertidumbre sobre la otra. Dado que las representaciones de una capa son vectores continuos y $I(X; Y)$ requiere variables discretas, los autores discretizan cada representación mediante agrupamiento no supervisado (*k-means*), asignando a cada instancia el identificador del clúster más cercano; esta etiqueta discreta de clúster reemplaza al vector continuo original en el cálculo de $I(X; Y)$.

c) Localización empírica de los picos de información:

Los autores identifican, para wav2vec2-Base (12 capas), una progresión jerárquica de tipo acústico-lingüístico:

- Capas 5-7 — contenido fonético. Tanto la información mutua entre la representación de la capa y la etiqueta real de fonema (MI-phone) como la similitud CCA contra *acoustically grounded word embeddings* (AGWE —embeddings entrenados para capturar específicamente similitud fonético-acústica) alcanzan su punto máximo en este rango.

- Capas 7-8 — contenido semántico. La similitud CCA entre la representación de la capa y embeddings de significado de palabra (GloVe) alcanza su máximo en un rango intermedio.
- Capas 9-11 — fase reconstructiva. Tanto MI-phone como MI-word decrecen fuertemente, lo que indica que el modelo deja de priorizar la información lingüística y empieza a reconstruir características cercanas a la entrada original.

Esta partición fonético/semántico/reconstructivo es el fundamento directo de la variante Inteligente, aplicada de forma consistente en los tres escenarios PEFT de esta tesis: descongelamiento parcial por bloques, adapters y LoRA usan la misma división en Bloque A (fonético), Bloque B (semántico) y Bloque C (reconstructivo) para decidir dónde intervenir, en comparación con las configuraciones de referencia agnósticas a la interpretabilidad de las salidas del modelo.

B. PEFT

La forma habitual de adaptar un modelo preentrenado a una tarea específica es el *fine-tuning* completo: se parte de los pesos aprendidos en el preentrenamiento y se continúa entrenando la totalidad de ellos con los datos etiquetados de la nueva tarea. Si Φ_0 son los pesos preentrenados, el fine-tuning completo aprende para cada tarea una actualización $\Delta\Phi$ del mismo tamaño que Φ_0 ; en consecuencia, cada tarea requiere almacenar una copia completa del modelo [14]. Adicionalmente, cuando tenemos un conjunto de datos pequeño para la tarea objetivo, ajustar la red en su totalidad puede resultar subóptimo [15], y reentrenar los pesos compartidos expone al modelo a olvidar las representaciones aprendidas previamente, fenómeno conocido como olvido catastrófico [15].

El ajuste fino eficiente en parámetros (PEFT, por sus siglas en inglés) aborda estas limitaciones manteniendo congelados los pesos preentrenados y entrenando únicamente un conjunto pequeño de parámetros nuevos. Houlsby et al [15], lo formalizan de la siguiente manera: Dada una red $\varphi_w(x)$ con parámetros preentrenados w , se define una nueva función $\psi_{w,v}(x)$ donde w se copia del preentrenamiento y permanece fijo mientras v es un conjunto de parámetros nuevos con

$|v| \ll |w|$. Los parámetros iniciales v_0 se eligen de modo que la nueva función reproduzca la original:

$$\psi_{w,v_0}(x) \approx \varphi_w(x) \quad (6)$$

De forma tal, que durante el entrenamiento solo se ajusta v . Esta condición de inicialización garantiza que el entrenamiento arranque exactamente desde el comportamiento del modelo preentrenado y se aleje de él de forma gradual desencadenando en dos atributos principales: el modelo resultante es compacto porque cada tarea añade solo unos pocos parámetros y adicionalmente es extensible debido a que se pueden incorporar tareas nuevas sin alterar los pesos compartidos con las tareas o dimensiones previamente entrenadas.




Fig. 3. Taxonomía de métodos PEFT, con los adapters y LoRA resaltados. Adaptada de Lialin et al. [16].

Las técnicas PEFT pueden clasificarse en tres clases principales según sea su enfoque [16]: los métodos aditivos, que aumentan el modelo preentrenado con parámetros o capas nuevas y entrenan únicamente esos elementos; los métodos selectivos, que ajustan un subconjunto de los

parámetros ya existentes del modelo, como las últimas capas de la red o únicamente sus sesgos; y los métodos de reparametrización, que aprovechan representaciones de bajo rango para expresar la actualización de los pesos con un número reducido de parámetros entrenables. A estas se suman los métodos híbridos, que combinan ideas de varias clases. Dentro de los métodos aditivos, a su vez, se distinguen dos grandes subgrupos: los métodos tipo adapter, que insertan pequeñas redes totalmente conectadas después de las sub-capas del Transformer, y los soft prompts, que ajustan mediante gradiente una parte de los *embeddings* de entrada del modelo. Estas técnicas buscan reducir el consumo de memoria, mejorar la eficiencia de almacenamiento o aportar modularidad, y difieren entre sí en la cantidad de parámetros entrenables y el costo de entrenamiento e inferencia [16].

1) Adaptadores (Adapters):

Un adapter es un módulo pequeño de parámetros nuevos que se inserta dentro de las capas de una red preentrenada cuyos pesos originales permanecen congelados; durante el entrenamiento solo se ajustan los parámetros del adapter [15]. A este modulo se le atribuyen dos características principales: un número reducido de parámetros en comparación con las capas de la red original, lo que hace que el tamaño total del modelo crezca lentamente a medida que se añaden tareas, y una inicialización cercana a la identidad, necesaria para que el entrenamiento sea estable.




Fig. 4. Estructura interna de un adapter bottleneck: proyección descendente, no linealidad y proyección ascendente, con conexión residual.

Para limitar el número de parámetros, el adapter adopta una arquitectura de cuello de botella (Fig. 5). Dada una representación de entrada $h \in \mathbb{R}^d$, una primera capa lineal (FF Down) la proyecta a una dimensión menor m , Sobre esta se aplica una no linealidad f , y una segunda capa lineal (FF Up) la proyecta de vuelta a las d dimensiones originales. El módulo incluye además una conexión residual interna que suma la entrada a esa transformación:

$$\text{Adapter}(h) = h + W_{up} f(W_{down} h + b_{down}) + b_{up} \quad (7)$$

Donde $W_{down} \in \mathbb{R}^{m \times d}$ y $b_{down} \in \mathbb{R}^m$ son los parámetros de FF Down, y $W_{up} \in \mathbb{R}^{d \times m}$ y $b_{up} \in \mathbb{R}^d$ los de FF Up. El número total de parámetros que añade cada adapter, incluyendo los sesgos es de $2md + d + m$.

Al fijar $m \ll d$, este número se mantiene pequeño; en la práctica, se utiliza entre el 0.5 y el 8% de los parámetros del modelo original [15]. Esta matriz se expresa mediante el factor de reducción r , que indica cuántas veces se reduce la dimensión oculta en el cuello de botella [17]:

$$r = \frac{d}{m}.$$

Por ejemplo, para una dimensión oculta $d = 768$, un factor $r = 64$ produce un cuello de botella de $m = 12$ dimensiones [Pfeiffer].

La suma residual interna es la que permite la inicialización cercana a la identidad: si los parámetros de ambas proyecciones se inicializan con valores próximos a cero, el término $W_{up} f(W_{down} h + b_{down}) + b_{up}$ es aproximadamente nulo y el módulo se reduce a $\text{Adapter}(h) \approx h$ [Houlsby]. De este modo, la red original no se ve afectada al inicio del entrenamiento, y es durante este que los adapters se activan para modificar las activaciones a lo largo de la red.

2). Low-Rank Adaptation (LoRA):

A diferencia de los adapters, que introducen módulos nuevos en la red (B.1), LoRA pertenece a los métodos de reparametrización, es decir, no añade capas extra al modelo, en su lugar, restringe la forma que puede tomar la actualización de los pesos ya existentes [14]. Este metodo se fundamenta en el comportamiento del rango $\text{rank}(W)$ de las matrices que se utilizaran para la actualización que se define como la dimensión del espacio generado por sus columnas, en otras palabras, el rango es el número máximo de columnas linealmente independientes que tiene una matriz.

La factorización de rango establece que toda matriz $M \in \mathbb{R}^{d \times k}$ con $\text{rank}(M) = r$ puede escribirse como el producto de dos matrices de dimensión intermedia r : $M = BA$, $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$ donde las r columnas de B forman una base del espacio columna de M , y cada columna de A contiene los coeficientes que expresan la columna correspondiente de M en esa base [Strang]. El número de valores necesarios para describir M pasa así de dk a $r(d + k)$, una reducción considerable cuando $r \ll \min(d, k)$.

Recíprocamente, cualquier producto de esta forma tiene rango a lo sumo r , ya que $\text{rank}(BA) \leq \min(\text{rank}(B), \text{rank}(A)) \leq r$. De esta manera aunque la matriz sea formalmente de rango completo, su contenido relevante vive en un subespacio de dimensión r . Hu et al. [14] se inspiran en trabajos previos que muestran que los modelos preentrenados pueden adaptarse eficientemente aun cuando el entrenamiento se restringe a un subespacio de parámetros de dimensión reducida [14]. A partir de ello formulan la hipótesis central de LoRA: la actualización de los pesos durante la adaptación tiene un "rango intrínseco" bajo [14]. Es decir, para cada matriz preentrenada W_0 , la actualización ΔW que la adapta a la tarea, aunque sea de la misma dimensión $d \times k$, concentra su contenido relevante en unas pocas direcciones, de modo que se cumple:

$$\text{rank}(\Delta W) = r \ll \min(d, k) \quad (8)$$




Fig. 5. Factorización de rango de la actualización de pesos ΔW en las matrices de bajo rango B y A .

Si esta hipótesis se cumple, no es necesario aprender ΔW entrada por entrada. Que esta matriz tenga rango r significa que todas sus columnas son combinaciones lineales de solo r vectores base. Por la factorización de rango, basta entonces con aprender dos matrices pequeñas: $B \in \mathbb{R}^{d \times r}$, cuyas columnas son esos r vectores base, y $A \in \mathbb{R}^{r \times k}$, que contiene, para cada columna de ΔW , los r coeficientes con los que se combinan dichos vectores. Su producto reconstruye la actualización completa:

$$\Delta W = BA \quad (9)$$

El número de parámetros a aprender pasa así de dk , (las entradas de ΔW), a $r(d + k)$, las entradas de B y A . Por ejemplo, para $d = k = 1024$ y $r = 8$, esto supone pasar de 1.048.576 a 16.384 parámetros, aproximadamente el 1.6% del total.

Dada una matriz preentrenada $W_0 \in \mathbb{R}^{d \times k}$, LoRA la mantiene congelada y suma a su salida la contribución de la actualización de bajo rango $\Delta W = BA$, escalada por un factor α/r [14]:

$$h = W_0 x + \frac{\alpha}{r} B A x \quad (10)$$

donde B y A son los únicos parámetros entrenables. A se inicializa con valores gaussianos aleatorios y B con ceros, de modo que $\Delta W = 0$ al inicio y la capa reproduce exactamente su comportamiento preentrenado.

En principio, LoRA puede aplicarse a cualquier matriz densa de la red [14]. En una capa Transformer, las candidatas son las cuatro proyecciones del módulo de atención (W_q, W_k, W_v, W_o) y las dos del módulo feed-forward. Adaptar una proyección de atención, por ejemplo W_q , consiste en sustituir $W_q x$ por $W_q x + \frac{\alpha}{r} B_q A_q x$, con $B_q \in \mathbb{R}^{d_{model} \times r}$ y $A_q \in \mathbb{R}^{r \times d_{model}}$; el resto del mecanismo de atención no cambia, añadiendo al modelo $2r d_{model}$ parámetros.

Métodos para elaborar citas y referencias

Recuerda, debes escoger solo un método para realizar las citas y las referencias, es decir, debes seleccionar entre un gestor especializado como Zotero, Mendeley, EndNote o LaTeX (confiabilidad alta), el gestor nativo Microsoft Word (confiabilidad media) o “manuales” (confiabilidad baja); no se deben mezclar entre sí, nuestra recomendación principal es Zotero, pues te permite almacenar, subrayar e insertar notas en PDF’s, guardar fichas bibliográficas, elaborar citas y bibliografías en APA, Vancouver, IEEE y más de 1.000 estilos diferentes, exportar registros, compartir documentos, etc. Sigue estos pasos:

1. Crear cuenta en Zotero: <https://www.zotero.org/user/register/>
2. Descargar e instalar aplicación de escritorio de Zotero (Windows, Mac, Linux): <https://www.zotero.org/download/>
3. Ingresar email y clave en Zotero de escritorio.
4. El plugin para insertar citas y referencias desde Microsoft Word se agrega automáticamente en la instalación. Si trabajas en línea con el editor Documentos de Google, es posible agregar la extensión para navegadores Zotero Connector para insertar citas y referencias.

IV. METODOLOGÍA

En la metodología se establecen los enfoques de investigación, esto es, cuantitativo, cualitativo o mixto.

Falta hablar de los modelos de W2V, base, large y multilingual

V. ANÁLISIS DE RESULTADOS

En los resultados se comunican los hallazgos y descubrimientos del estudio. Se incluyen tablas, figuras, diagramas y demás material demostrativo. Al narrar descriptivamente una figura, tabla, etc., en un párrafo, puedes insertar una referencia cruzada, es decir, un hipervínculo al elemento mencionado dentro o fuera de paréntesis, ejemplos: estos resultados se muestran en la **TABLA I**. Igualmente, los datos son validados con otros instrumentos (). Lineamientos que se establecen en la nueva versión de las Normas IEEE (**Fig. 6**). La producción intelectual institucional se publica en el Repositorio (**Fig. 7**).

TABLA I
RESULTADOS DEL TEST

Código	Parámetro	Valor
V154	+521	125
V245	-654	254
V874	-214	478
V957	+254	852

Nota: variación de resultados de pruebas aleatorias.

TABLA II
CATEGORÍAS DE INVESTIGACIÓN

Categoría	Subtemas	Definiciones
Memoria	Memoria de trabajo	Es una función ejecutiva cerebral que se encarga del almacenamiento de la información que llega del exterior, con la cual se construyen los conocimientos.
	Bases neurológicas	Las bases neurológicas de la memoria se relacionan con el lóbulo prefrontal.
Estrategias	Estrategias lúdicas	Las estrategias lúdicas son las acciones que planean los docentes, donde intervienen el disfrute, el goce y el placer en la construcción de los conocimientos.
	Estrategias didácticas	Las estrategias didácticas son las acciones de los maestros a partir de las cuales los estudiantes construyen los conocimientos; pueden ser estrategias de aprendizaje o de enseñanza.
Proceso de aprendizaje del idioma inglés	Aprendizaje	Es un proceso cognitivo de asimilación, donde los estudiantes unen las nuevas informaciones con saberes previos, a través de un proceso cognitivo.
	Estilos de aprendizaje	El aprendizaje se puede dar a través de los sentidos. Es así como existen, básicamente, tres estilos o formas de adquirir los conocimientos: el visual, el auditivo y el kinestésico.



Fig. 6. Imagen corporativa Institute of Electrical and Electronics Engineers (IEEE)

Nota: fuente <https://www.ieee.org/> Esta entidad edita y normaliza la presentación de documentos científicos en el área de ingenierías.



Fig. 7. Logo Universidad de Antioquia

Nota. Fuente <http://www.udea.edu.co>

VI. CONCLUSIONES Y RECOMENDACIONES

Son las interpretaciones finales que recopilan los datos del trabajo final, describe lo que se obtuvo, qué se logró y cuáles son los resultados. Guarda relación directa con los objetivos planteados. Las recomendaciones hacen alusión a los trabajos futuros que se podrían realizar para dar continuidad al tema de la práctica o para completar o mejorar los resultados obtenidos.

REFERENCIAS

- [1] “Global action plan on the public health response to dementia 2017 - 2025”. Consultado: el 25 de septiembre de 2026. [En línea]. Disponible en: <https://www.who.int/publications/i/item/global-action-plan-on-the-public-health-response-to-dementia-2017---2025>
- [2] “La epidemia de demencia avanza silenciosa con el envejecimiento en Colombia”. Consultado: el 25 de septiembre de 2026. [En línea]. Disponible en: <https://www.periodico.unal.edu.co/articulos/la-epidemia-de-demencia-avanza-silenciosa-con-el-envejecimiento-en-colombia>
- [3] A. Guerrero-Barragán y D. I. Lucumi-Cuesta, “Stakeholder perceptions of dementia in Colombia: a qualitative study”, *BMC Public Health*, vol. 25, núm. 1, p. 959, mar. 2025, doi: 10.1186/s12889-025-22166-9.
- [4] A. Giudicessi *et al.*, “Cognitive Outcomes in Autosomal-Dominant Alzheimer’s Disease: A Comprehensive Review from a Colombian Kindred with the Presenilin-1 E280A Mutation”, *Journal of Alzheimer’s Disease*, vol. 101, núm. 2, pp. 397–415, sep. 2024, doi: 10.3233/JAD-240360.
- [5] I. Vigo, L. Coelho, y S. Reis, “Speech- and Language-Based Classification of Alzheimer’s Disease: A Systematic Review”, *Bioengineering*, vol. 9, núm. 1, p. 27, ene. 2022, doi: 10.3390/bioengineering9010027.
- [6] A. D. Assfaw, S. E. Schindler, y J. C. Morris, “Advances in blood biomarkers for Alzheimer disease (AD): A review”, *The Kaohsiung J of Med Scie*, vol. 40, núm. 8, pp. 692–698, ago. 2024, doi: 10.1002/kjm2.12870.
- [7] A. Baevski, H. Zhou, A. Mohamed, y M. Auli, “wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations”, el 22 de octubre de 2020, *arXiv*: arXiv:2006.11477. doi: 10.48550/arXiv.2006.11477.
- [8] S. Luz, F. Haider, S. de la Fuente, D. Fromm, y B. MacWhinney, “Alzheimer’s Dementia Recognition through Spontaneous Speech: The ADReSS Challenge”, el 5 de agosto de 2020, *arXiv*: arXiv:2004.06833. doi: 10.48550/arXiv.2004.06833.
- [9] N. Houlsby *et al.*, “Parameter-Efficient Transfer Learning for NLP”, el 13 de junio de 2019, *arXiv*: arXiv:1902.00751. doi: 10.48550/arXiv.1902.00751.
- [10] E. J. Hu *et al.*, “LoRA: Low-Rank Adaptation of Large Language Models”, el 16 de octubre de 2021, *arXiv*: arXiv:2106.09685. doi: 10.48550/arXiv.2106.09685.
- [11] D. S. Park *et al.*, “SpecAugment: A Simple Data Augmentation Method for Automatic Speech Recognition”, en *Interspeech 2019*, ISCA, sep. 2019, pp. 2613–2617. doi: 10.21437/Interspeech.2019-2680.
- [12] A. Baevski, H. Zhou, A. Mohamed, y M. Auli, “wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations”, el 22 de octubre de 2020, *arXiv*: arXiv:2006.11477. doi: 10.48550/arXiv.2006.11477.
- [13] A. Pasad, B. Shi, y K. Livescu, “Comparative layer-wise analysis of self-supervised speech models”, el 16 de marzo de 2023, *arXiv*: arXiv:2211.03929. doi: 10.48550/arXiv.2211.03929.
- [14] E. J. Hu *et al.*, “LoRA: Low-Rank Adaptation of Large Language Models”, el 16 de octubre de 2021, *arXiv*: arXiv:2106.09685. doi: 10.48550/arXiv.2106.09685.

- [15] N. Houlsby *et al.*, “Parameter-Efficient Transfer Learning for NLP”, el 13 de junio de 2019, *arXiv*: arXiv:1902.00751. doi: 10.48550/arXiv.1902.00751.
- [16] V. Lialin, V. Deshpande, X. Yao, y A. Rumshisky, “Scaling Down to Scale Up: A Guide to Parameter-Efficient Fine-Tuning”, el 22 de noviembre de 2024, *arXiv*: arXiv:2303.15647. doi: 10.48550/arXiv.2303.15647.
- [17] J. Pfeiffer, A. Kamath, A. Rücklé, K. Cho, y I. Gurevych, “AdapterFusion: Non-Destructive Task Composition for Transfer Learning”, en *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume*, Online: Association for Computational Linguistics, 2021, pp. 487–503. doi: 10.18653/v1/2021.eacl-main.39.

ANEXOS

En los anexos se incluye material complementario que apoya la documentación investigativa, tales como consentimientos informados, entrevistas, material fotográfico, etc. Evite incluir material que puede estar protegido por derechos de autor, tales como pruebas psicológicas, fragmentos de libros, artículos de revistas, patentes, etc. Recuerda no incluir en tu documento datos de personas o entidades objetos de la investigación, tales como nombres, apellidos, cédulas, números telefónicos, consentimientos informados con datos personales (Resolución 8430 de 1993), nombres de empresas sin el consentimiento escrito del representante legal, fotografías en primer plano de personas (especialmente de menores de edad) y demás información que pueda contravenir los principios emitidos en la Ley Estatutaria 1581 de 2012 (Ley de protección de datos personales).

Los siguientes anexos contienen documentos de interés para el proceso de trabajo de grado, así como trucos y recomendaciones que surgen constantemente en la elaboración de un documento en Word.

Anexo A. Autoarchivo en Repositorio y documentos de interés

Consulte el instructivo de autoarchivo en el este [enlace](#).

Anexo B. Póster Autoarchivo en Repositorio y documentos de interés

En último lugar, se incluye el anexo del poster que utilizarás en la jornada de prácticas académicas, en caso de aplicar. Guárdelo de forma tal que no modifique el tamaño de las hojas ni afecte la presentación del documento.